

Aula anterior

Indexação invertida:

- Introdução
- Termos de Indexação e Vocabulário
- Matriz de termos
- Índice Invertido

Pesquisa Digital

Prof. Diego Silva Caldeira Rocha

Objetivos

- Introdução a Pesquisa Digital
- Árvore Trie
- Árvore Patrícia

Pesquisa Digital

- Pesquisa digital é baseada na representação das chaves como uma sequência de caracteres ou de dígitos.
- Os métodos de pesquisa digital são particularmente vantajosos quando as chaves são grandes e de tamanho variável.
- Estruturas geralmente utilizadas para a pesquisa digital são as árvores digitais
- Exemplos:
 - Trie
 - Patrícia

Árvores Trie

- Estruturas de dados para a procura rápida de padrões
- Usadas em aplicações de pré-processamento do texto
- Nome derivado da palavra *retrieval* (recuperação)
- Aplicadas, por exemplo, em: índices, armazenamento de palavras (dicionários) ortografia, Compressão de dados, e busca de uma sequência de DNA em uma base de genomas

Definição

- Tem-se uma coleção de S cadeias de caracteres (ou palavras) utilizando o mesmo alfabeto e as operações primárias suportadas são:
 - Procura de padrões
 - Procura de prefixos: Recebe-se uma palavra X e retornam-se todas as palavras que têm X como prefixo

Árvore Digital Binária

- Árvore digital binária é uma árvore digital m-ária com $m=2$.
- O alfabeto é composto por $\{0,1\}$
- A aresta esquerda representa o dígito 0 e a direita o dígito 1

Árvore Digital Binária

- Chaves:

00

0000

00010

00011


010110

010111


10

101

1010



Exemplo



bear - urso

bell - sino

bid - oferta

bull - touro


buy - compra

sell - vende

stock - ação


stop - parar

Exemplo (outra representação)




Exercício Resolvido (1)

- Insira as palavras sapo e sapato na árvore abaixo




Exercício Resolvido (1)

- Insira as palavras **sapo** e sapato na árvore abaixo



Exercício Resolvido (1)

- Insira as palavras sapo e sapato na árvore abaixo



Propriedades

- Nenhuma cadeia de S é prefixo de outra cadeia
- Cada nó (exceto a raiz) é rotulado com um caractere do Σ
- A árvore tem s folhas, uma para cada cadeia de S
- Em um caminho da raiz até uma folha, a concatenação dos rótulos resulta na cadeia associada a essa folha

Propriedades

- Cada nó interno tem no máximo $d = |\Sigma|$ filhos
- Em geral, a *trie* é uma árvore múltipla ($0 \dots d$ filhos)
- Quando d igual a 2, a *trie* será uma árvore binária
- A altura da árvore é igual ao tamanho da maior cadeia da coleção, $d_{\text{máximo}}$

Propriedades

- Seja n o número total de caracteres de S , o número de nós é $\Theta(n)$
- O pior caso para o número de nós acontece quando não existe qualquer prefixo comum entre as cadeias, fazendo com que todos os nós internos (exceto a raiz) tenham um filho


Pesquisar por uma Cadeia de Caracteres

- A partir da raiz, verificamos caractere-a-caractere se existe um caminho na árvore correspondendo à cadeia desejada
- Por definição, um caminho sempre termina em uma folha


Trie

- Significa *Practical Algorithm to Retrieve Information Coded in Alphanumeric*
- Elimina os nós redundantes fazendo com que todos os nós (exceto a raiz) tenham pelo menos dois filhos
- Na *trie-padrão*, a existência de nós com apenas um filho representa ineficiência em termos de espaço

Exemplo de Trie




bear - urso
bell - sino
bid -
 oferta *bull*
 - touro
buy -
 compra *sell*
 -
 vende *stock* -
 ação *stop* -
 parar




Exercício Resolvido (1)

- Insira as palavras sapo e sapato na árvore abaixo




Exercício Resolvido (1)

- Insira as palavras **sapo** e sapato na árvore abaixo



Exercício Resolvido (1)

- Insira as palavras sapo e sapato na árvore abaixo



Propriedades das Trie

- Nós rotulados por *substrings* das cadeias de caracteres da coleção S
- Temos $\Theta(s)$ nós, onde s é o número de cadeias da coleção
- O número de nós é proporcional ao número de cadeias da coleção S; não ao comprimento das mesmas
- Todo nó interno tem entre 2 e d filhos

Estrutura de Dados das *Trie*

- Cada nó armazena uma tripla de inteiros (i, j, k) , indicando o rótulo do nó de tal forma que $S[i][j...k]$, onde:
 - A coleção de cadeias S será $S[0], S[1], \dots S[s-1]$
 - j e k representam, respectivamente, a primeira e última (inclusive) posições da cadeia $S[i]$ que correspondem ao rótulo corrente

Exercício Resolvido (2)

- Na figura, identifique a substring representada por cada nó

0 1 2 3 4

s[0] =

s	e	e
---	---	---

0 1 2 3

s[4] =

b	u	l	l
---	---	---	---

0 1 2 3

s[7] =

h	e	a	r
---	---	---	---

s[1] =

b	e	a	r
---	---	---	---

s[5] =

b	u	y
---	---	---

s[8] =

b	e	l	l
---	---	---	---

s[2] =

s	e	l	l
---	---	---	---

s[6] =


b	i	d
---	---	---

s[9] =

s	t	o	p
---	---	---	---


s[3] =

s	t	o	c	k
---	---	---	---	---



Exercício Resolvido (3)

- Insira as palavras sapo e sapato na árvore abaixo



Exercícios

- 1) Faça a representação de uma árvore trie binária com os valores: 1 , 1111, 001, 010, 110 e 0001.
- 2) Faça a inserção manual de palavras em duas estruturas de dados: uma árvore Trie e uma árvore Trie Patricia. Seu objetivo é desenhar manualmente as estruturas conforme as palavras são inseridas, mostrando passo a passo a evolução da árvore.
 - a) Lista de Palavras:["apple", "banana", "orange", "app", "ban"]