

Aula Passada

Tabela Hash: Tratamento de Colisões por Encadeamento Exterior

- Introdução
- Encadeamento Exterior
- Busca
- Inserção de um Registro
- Exclusão de um Registro
- Complexidade
- Implementação em Disco
- Exclusão
- Inserção
- Exercício

Indexação Invertida

Diego Silva Caldeira Rocha

Sumário

Introdução

Termos de Indexação e Vocabulário

Matriz de termos

Índice Invertido


Introdução

- BD usualmente adoram termos de indexação para indexar e recuperar Registros.
- Um **termo de indexação** consiste de uma palavra ou um grupo de palavras consecutivas em um Registro.
- Usualmente *stopwords* como artigos, preposições, adjetivos e advérbios não são considerados termos de indexação pois não trazem informação relevante para auxiliar na recuperação.
- Sistemas de BD comumente também agrupam sinônimos em um mesmo termo de indexação.

Termos de Indexação e Vocabulário

- Considere ainda t como o número de termos de indexação na coleção de registros R e k_i com um termo de indexação genérico.
- $V = \{k_1, \dots, k_t\}$ é o conjunto de todos os termos de indexação distintos na coleção e é conhecido como **vocabulário V** da coleção.
- O tamanho do vocabulário é t .

Termos de Indexação e Vocabulário



- Nesse exemplo temos quatro documentos, $R = \{r_1, r_2, r_3, r_4\}$ e treze termos de indexação ($t = 13$) no vocabulário $V = \{\text{"se", "eu", "for", "vou", "não", "sou", "o", "que", "pensam", "louco", "pra", "casa", "agora"}\}$.

Matriz de Termos

- Para ilustrar, a abaixo apresenta os termos que representa a coleção de registros do exemplo.

Palavra	R ₁	R ₂	R ₃	R ₄
se	2	0	0	0
eu	4	2	1	3
for	2	0	0	0
vou	2	0	0	3
não	2	1	1	0
sou	0	3	2	0
o	0	2	0	0
que	0	2	1	0
pensam	0	1	1	0
louco	0	0	2	0
pra	0	0	0	1
casa	0	0	0	1
agora	0	0	0	1

Índice Invertido

- A matriz de termos é a forma mais simples de representar o número de ocorrências de palavras em uma coleção de documentos.
- Todavia, essa matriz requer $R \times t$ posições de memória para seu armazenamento.
- Em coleções reais e na busca de informação no banco de dados é comumente inviável dispor de memória para armazenar essa estrutura.

Índice Invertido

- Como alternativa, o índice invertido faz uso mais eficiente da memória para computar a relação de ocorrências em documentos.
- Em um índice invertido, cada palavra compõe um índice, que por sua vez possui uma lista dos documentos nos quais essa palavra ocorre e o número de ocorrências em cada documento.

Índice Invertido

- Coleção do exemplo representada por uma estrutura de índice invertido, onde cada posição de um índice é expressa pelo par [registro, ocorrências].

Palavra	Índice Invertido
se	[r_1 , 2]
eu	[r_1 , 4], [r_2 , 2], [r_3 , 1], [r_4 , 3]
for	[r_1 , 2]
vou	[r_1 , 2], [r_4 , 3]
não	[r_1 , 2], [r_2 , 1], [r_3 , 1]
sou	[r_2 , 3], [r_3 , 2]
o	[r_2 , 2]
que	[r_2 , 2], [r_3 , 1]
pensam	[r_2 , 1], [r_3 , 1]
louco	[r_3 , 2]
pra	[r_4 , 1]
casa	[r_4 , 1]
agora	[r_4 , 1]

Exemplo de Consulta

Palavra	Índice Invertido
se	$[r_1, 2]$
eu	$[r_1, 4], [r_2, 2], [r_3, 1], [r_4, 3]$
for	$[r_1, 2]$
vou	$[r_1, 2], [r_4, 3]$
não	$[r_1, 2], [r_2, 1], [r_3, 1]$
sou	$[r_2, 3], [r_3, 2]$
o	$[r_2, 2]$
que	$[r_2, 2], [r_3, 1]$
pensam	$[r_2, 1], [r_3, 1]$
louco	$[r_3, 2]$
pra	$[r_4, 1]$
casa	$[r_4, 1]$
agora	$[r_4, 1]$

- Consulta: “vou pra casa”
 - Primeiro termo: “vou” Conjunto $\{1,4\}$
 - Segundo termo: “pra” Conjunto $\{4\}$
 - Terceiro termo: casa $\{4\}$
- Resposta $\{4\}$ (interseção do ter conjuntos)

Visão Lógica dos Arquivos Invertidos

Em BD muito grandes, pode ser interessante, por razões de eficiência, reduzir o conjunto de palavras-chave representativas.

- Isso pode ser feito eliminando-se artigos e preposições.
- Reduz palavras distintas a sua raiz gramatical comum.
- Identificando-se os grupos de substantivos (o que elimina adjetivos, advérbios e verbos).
- Essas transformações reduzem a complexidade da representação dos Registro permitem mudar a representação de *full-text* para a de um conjunto de termos de indexação.

Estrutura de um Arquivo com Índice Invertido

Vantagem

- Permite o acesso direto a um conjunto de registros

Desvantagem

- As listas só são válidas para aquela disposição física
 - Se o arquivo sofrer uma reorganização, as inversões terão que ser regeradas
- Para superar esta desvantagem, pode-se implementar as listas por chaves primárias.

Exercícios

1) Considere a coleção de registros apresentada na figura abaixo e exiba sua representação computacional por índice invertido, aplique as regras de reduções de palavras.

Ai se eu te pego, ai, ai se eu te pego.	Aí eu bebo, aí eu bebo! Bebo pra carai!	Só eu que bebo? Será que só eu que bebo.	Ai, ai, ai, ai esse amor, é bom demais
r_1	r_2	r_3	r_4

Referência

Baeza-Yates, R; Ribeiro-Neto, B. *Modern Information Retrieval: The Concepts and Technology behind Search*. 2ª edição. Pearson, 2011 (capítulo 2).